

TP2 : Clustering K-means / Hclust – Implémentation

Établissement : Institut de Formation et de Recherche en Informatique (IFRI)

Formation : Master 1 Génie Logiciel

Module : Big Data

Travail Pratique : TP2 – Clustering non supervisé

Année académique : 2025-2026

Étudiant : Brice GOUDALO

Enseignant : Dr. John AOGA

Date de remise : 20 Mai 2026

Code Github : <https://github.com/Harley755/clustering-k-means-hclust>

Table des matières:

1. Objectifs du TP.....	3
2. Présentation de la dataset.....	3
2.1. Justification du choix.....	3
2.2. Source et génération.....	3
2.3. Description des variables.....	4
2.4. Caractéristiques dimensionnelles.....	5
3. Prétraitement des données.....	5
3.1. Gestion des valeurs manquantes.....	5
3.2. Encodage des variables catégorielles.....	6
3.3. Normalisation / Standardisation.....	6
3.4. Sélection des features.....	6
4. Implémentation et résultats K-means.....	7
4.1. Paramétrage du modèle.....	7
4.2. Résultats de la convergence.....	7
4.3. Distribution des clusters obtenus.....	7
4.4. Métriques d'évaluation.....	8
4.5. Profils moyens des clusters K-means.....	9
5. Fondements théoriques du Clustering Hiérarchique.....	9
5.1. Principe général.....	9
5.2. Le Dendrogramme.....	10
5.3. Méthodes de liaison (Linkage).....	10
5.4. Coefficient Cophénétique.....	11

5.5. Avantages et limites.....	11
6. Implémentation et résultats du Clustering Hiérarchique.....	12
6.1. Stratégie d'implémentation.....	12
6.2. Résultats du coefficient cophénétique.....	12
6.3. Distribution des clusters Hclust.....	13
6.4. Métriques d'évaluation.....	13
6.5. Profils moyens des clusters Hclust.....	14
7. Visualisations et analyse graphique.....	14
7.1. Méthode Elbow (K-means).....	14
7.2. Silhouette Score.....	15
7.3. Projection PCA (K-means et Hclust).....	15
7.4. Dendrogramme hiérarchique.....	17
7.5. Heatmaps des profils.....	17
7.6. Boxplots comparatifs.....	18
7.7. Comparaison côte-à-côte.....	19
8. Analyse comparative K-means vs Hclust.....	20
8.1. Comparaison quantitative des métriques.....	20
8.2. Comparaison qualitative.....	20
8.3. Analyse des cas d'usage recommandés.....	21
8.4. Discussion sur la convergence des résultats.....	22
9. Conclusion.....	22

1. Objectifs du TP

Ce travail pratique poursuit les objectifs pédagogiques suivants :

- Implémenter et exécuter l'algorithme K-means sur une dataset réaliste
- Implémenter et exécuter le Clustering Hiérarchique Agglomératif (CAH)
- Maîtriser les méthodes de sélection du nombre optimal de clusters
- Évaluer la qualité des partitions à l'aide de métriques internes et externes
- Comparer les deux approches selon des critères multidimensionnels
- Interpréter les résultats d'un point de vue métier

2. Présentation de la dataset

2.1. Justification du choix

Le cas d'usage retenu est la segmentation de clients d'une enseigne de grande distribution fictive, baptisée *MarketIFRI*. Ce choix est motivé par plusieurs considérations :

- Réalisme : la segmentation clients est l'une des applications les plus répandues du clustering en entreprise (Amazon, Cdiscount, Carrefour...)
- Richesse analytique : les données comportementales de consommation produisent des clusters naturellement interprétables
- Pédagogie : les profils obtenus sont facilement compréhensibles et discutables
- Pertinence : cette application illustre parfaitement les forces et limites comparatives des deux algorithmes étudiés

2.2. Source et génération

La dataset a été synthétiquement générée via le script `generate_dataset.py`, conformément aux bonnes pratiques académiques lorsqu'aucune source de données réelle ne peut être utilisée sans restrictions légales (RGPD, confidentialité). Le processus de

génération simule des distributions statistiques réalistes issues de la littérature du marketing quantitatif.

2.3. Description des variables

Variable	Type	Description	Plage
client_id	String	Identifiant unique du client	C00001-C02000
age	Integer	Âge du client	18-75 ans
revenu_annuel	Float	Revenu annuel estimé	10 000-150 000 €
score_depenses	Integer	Propension à dépenser (score calculé)	0-100
nb_achats_annuel	Integer	Nombre d'achats dans l'année	1-120
panier_moyen	Float	Valeur moyenne d'un achat	5-500 €
anciennete_mois	Integer	Durée de la relation client (mois)	1-120
ratio_promo	Float	Part des achats en promotion	0-1
score_fidelite	Integer	Score de fidélité composite	0-100
categorie_preferee	String	Catégorie d'achat dominante	9 catégories
canal_principal	String	Canal d'achat préférentiel	Magasin / En ligne / App
profil_reel	String	Label de vérité terrain	5 profils

2.4. Caractéristiques dimensionnelles

- Nombre d'observations : 2 000 clients
- Nombre de variables : 12 (dont 10 utilisées pour le clustering)
- Variables numériques : 8 (quantitatives continues ou discrètes)
- Variables catégorielles : 2 (encodées avant clustering)
- Taille fichier CSV : ~153 Ko (bien en deçà de la limite de 100 Mo)
- Valeurs manquantes : ~2 % sur 4 colonnes numériques (simulées)

3. Prétraitement des données

3.1. Gestion des valeurs manquantes

La dataset présente environ 2 % de valeurs manquantes sur quatre variables numériques (`revenu_annuel`, `panier_moyen`, `anciennete_mois`, `ratio_promo`), simulant des données réelles incomplètes. Trois stratégies d'imputation existent :

- Suppression des lignes (*listwise deletion*) : simple mais introduit un biais si les valeurs ne sont pas manquantes de façon totalement aléatoire (MCAR)
- Imputation par la moyenne : sensible aux valeurs extrêmes
- Imputation par la médiane : robuste aux outliers et adaptée aux distributions asymétriques ✓

Choix retenu : imputation par la médiane, car les variables concernées présentent des queues de distribution droites (revenus, paniers), et les algorithmes de clustering sont sensibles aux valeurs extrêmes.

```
# Imputation médiane
for col in ["revenu_annuel", "panier_moyen", "anciennete_mois", "ratio_promo"]:
    df[col].fillna(df[col].median(), inplace=True)
```

Résultats : 137 valeurs manquantes traitées ; aucune valeur résiduelle.

3.2. Encodage des variables catégorielles

Les variables `categorie_preferee` (9 modalités) et `canal_principal` (3 modalités) sont transformées en entiers via `LabelEncoder`. Ce choix est discutable pour K-means (`LabelEncoder` introduit un ordre arbitraire), mais il est justifié ici car :

- Ces variables ont un poids faible dans la variance totale
- Les distances induites restent cohérentes avec l'échelle standardisée
- L'encodage one-hot aurait significativement augmenté la dimensionnalité

Dans un projet de production, on préférerait un encodage ordinal raisonné ou une distance de Gower pour données mixtes.

3.3. Normalisation / Standardisation

Les variables numériques ont des échelles très hétérogènes : le revenu varie de 10 000 à 150 000 € tandis que le ratio de promotion varie de 0 à 1. Sans normalisation, les variables à grande amplitude dominent la distance euclidienne, biaisant les clusters vers ces dimensions.

Choix retenu : standardisation Z-score via `StandardScaler` de `scikit-learn` :

$$x'_i = (x_i - \mu) / \sigma$$

Cette transformation garantit $\mu' = 0$ et $\sigma' = 1$ pour chaque variable, leur conférant un poids équivalent dans le calcul des distances.

La normalisation min-max (0-1) aurait été une alternative valable, mais elle est davantage sensible aux outliers. Le Z-score est préféré en pratique académique et industrielle pour le clustering.

3.4. Sélection des features

Les 10 features retenues pour le clustering excluent `client_id` (identifiant non informatif) et `profil_reel` (label de vérité terrain conservé uniquement pour l'évaluation externe). L'ensemble des features numériques et encodées est utilisé, sans réduction de

dimensionnalité préalable – la PCA est appliquée uniquement pour la visualisation.

4. Implémentation et résultats K-means

4.1. Paramétrage du modèle

```
km = KMeans(  
    n_clusters    = 5,          # k choisi par méthode Elbow + Silhouette  
    init          = "k-means++", # Initialisation intelligente  
    n_init        = 20,         # 20 initialisations → retient la meilleure  
    max_iter      = 500,        # Maximum d'itérations par run  
    tol           = 1e-4,       # Seuil de convergence sur les centroïdes  
    random_state  = 42,         # Reproductibilité  
)
```

Justification de k=5 : bien que l'analyse automatique du Silhouette Score suggère k=3 comme optimum statistique, le choix de k=5 est justifié par la connaissance métier des 5 profils clients réels. Cette situation – décision hybride algorithme/expert – est standard en Data Science pratique. Par ailleurs, l'Elbow curve montre un coude marqué entre k=3 et k=5, confirmant que 5 groupes est une partition raisonnable.

4.2. Résultats de la convergence

Convergence en 6 itérations

Inertie finale : 7 065.15

La convergence rapide en 6 itérations témoigne d'une structure de données bien définie et de l'efficacité de l'initialisation K-means++.

4.3. Distribution des clusters obtenus

Cluster	Effectif	Proportion	Profil identifié
0	372	18,6 %	Chasseurs de promotions

Cluster	Effectif	Proportion	Profil identifié
1	291	14,6 %	Aisés premium
2	389	19,4 %	Seniors fidèles
3	521	26,1 %	Familles actives
4	427	21,4 %	Jeunes économes

4.4. Métriques d'évaluation

Métrique	Valeur	Interprétation
Silhouette Score	0.3002	Cohésion/séparation acceptables pour 10D
Calinski-Harabász	903.44	Bon rapport variance inter/intra
Davies-Bouldin	1.3248	Similarité inter-clusters modérée
ARI (vs vérité)	0.9204	Excellent accord avec les profils réels

Un ARI de 0.92 signifie que K-means retrouve correctement 92 % des affectations réelles – performance remarquable pour un algorithme non supervisé sur données à 10 dimensions. Cela valide la robustesse des profils simulés et la pertinence du clustering.

Le Silhouette Score de ~0.30, bien qu'inférieur à 0.5, est typique pour des espaces de haute dimensionnalité (10D) où la concentration des distances (phénomène du *curse of dimensionality*) compresse les écarts relatifs.

4.5. Profils moyens des clusters K-means

Cluster	Âge	Revenu	Score dépen.	Panier	Fidélité	Ratio promo
0 (Chasseurs promo)	36	25 187 €	55	38,8 €	46	0.70
1 (Aisés premium)	43	85 544 €	80	201,2 €	72	0.08
2 (Seniors fidèles)	62	35 517 €	49	55,0 €	84	0.20
3 (Familles actives)	38	41 490 €	60	83,4 €	62	0.30
4 (Jeunes économes)	24	18 350 €	36	23,8 €	29	0.48

Ces profils sont remarquablement distincts et interprétables – signe d'une partition de qualité.

5. Fondements théoriques du Clustering Hiérarchique

5.1. Principe général

Le Clustering Hiérarchique (ou CAH – Classification Ascendante Hiérarchique) est une famille d'algorithmes qui construit une hiérarchie de partitions plutôt qu'une partition unique. Il en existe deux variantes :

- Agglomératif (*bottom-up*) : chaque observation commence comme son propre cluster, puis les clusters les plus proches sont fusionnés progressivement → approche retenue
- Divisif (*top-down*) : tous les points forment un seul cluster, puis on subdivise récursivement

L'approche agglomérative, plus courante, produit un dendrogramme : une structure arborescente représentant la séquence des fusions, permettant de visualiser la hiérarchie complète des clusters à toutes les granularités.

5.2. Le Dendrogramme

Le dendrogramme est un graphique bipartite où :

- L'axe horizontal représente les observations (ou clusters)
- L'axe vertical représente la distance de fusion (hauteur à laquelle deux clusters sont fusionnés)
- Chaque jointure horizontale représente une fusion de deux clusters

Pour obtenir k clusters à partir du dendrogramme, on effectue une coupure horizontale à la hauteur h telle que k lignes verticales soient traversées. En pratique, on coupe là où le saut vertical (entre deux fusions successives) est maximal – signe que les clusters fusionnés sont de plus en plus distincts.

5.3. Méthodes de liaison (Linkage)

La notion de *distance entre deux clusters* C_i et C dépend de la méthode de liaison choisie :

Méthode	Formule	Propriétés
Single linkage	$\min_{\{x \in C_i, y \in C\}} d(x, y)$	Sensible aux chaînes ; clusters allongés
Complete linkage	$\max_{\{x \in C_i, y \in C\}} d(x, y)$	Clusters compacts ; sensible aux outliers
Average linkage	$(1/$	C_i

Méthode	Formule	Propriétés
Ward	$\Delta J = J(C_i \cup C_j) - J(C_i) - J(C_j)$	Minimise la variance ; clusters équilibrés ✓

Choix de la méthode Ward : la liaison de Ward (Ward, 1963) fusionne à chaque étape les deux clusters dont la fusion minimise l'augmentation de l'inertie totale. Elle tend à produire des clusters compacts et de taille équilibrée, ce qui la rend particulièrement adaptée à la segmentation clients où l'on souhaite des groupes homogènes et interprétables. C'est la méthode recommandée par défaut dans la littérature (Murtagh & Legendre, 2014).

5.4. Coefficient Cophénétique

Le coefficient cophénétique c mesure la corrélation entre les distances de fusion du dendrogramme et les distances originales entre points. Il quantifie la qualité de représentation hiérarchique :

$$c = \text{corr}(d_{\text{originale}}(x_i, x_j), d_{\text{dendro}}(x_i, x_j))$$

- $c > 0.90$: excellente représentation
- $c > 0.75$: bonne représentation
- $c < 0.60$: représentation insuffisante

Dans nos expériences : $c = 0.693$ – représentation acceptable, cohérente avec la haute dimensionnalité (10D) qui compresse les contrastes de distance.

5.5. Avantages et limites

Avantages :

- Ne nécessite pas de spécifier k a priori (la coupure peut être choisie a posteriori)
- Produit une représentation hiérarchique complète (dendrogramme)
- Déterministe (pas d'aléatoire dans Ward)

- Interprétation à plusieurs niveaux de granularité
- Compatible avec toute mesure de distance ou de similarité

Limites :

- Complexité quadratique en mémoire : $O(n^2)$ – problématique pour $n > 100\ 000$
- Complexité algorithmique naïve : $O(n^3)$; réduite à $O(n^2 \log n)$ avec les algorithmes modernes (SLINK, CLINK)
- Pas de réaffectation possible après fusion (erreurs cumulées)
- Sensible aux outliers (surtout en single et complete linkage)
- Dendrogramme illisible pour $n >$ quelques milliers

6. Implémentation et résultats du Clustering Hiérarchique

6.1. Stratégie d'implémentation

L'implémentation repose sur deux composants complémentaires :

- `scipy.cluster.hierarchy` : pour le calcul du dendrogramme sur un sous-échantillon de 500 observations (lisibilité + performance)
- `sklearn.cluster.AgglomerativeClustering` : pour l'attribution des labels sur la dataset complète (2 000 observations)

Dendrogramme sur sous-échantillon

```
# Dendrogramme sur sous-échantillon
Z = linkage(X_sample, method="ward", metric="euclidean")

# Clustering complet
modele = AgglomerativeClustering(
    n_clusters = 5,
    linkage = "ward",
    metric = "euclidean",
)
labels = modele.fit_predict(X_scaled)
```

6.2. Résultats du coefficient cophénétique

Coefficient cophénétique : 0.6928

Qualité de représentation : Acceptable

Cette valeur modérée s'explique par la haute dimensionnalité des données (10D), phénomène bien documenté dans la littérature (Houle et al., 2010). En espace de haute dimension, les distances sont concentrées et les structures hiérarchiques moins marquées.

6.3. Distribution des clusters Hclust

Cluster	Effectif	Proportion	Profil identifié
0	405	20,2 %	Seniors fidèles
1	484	24,2 %	Familles actives
2	308	15,4 %	Aisés premium
3	414	20,7 %	Jeunes économes
4	389	19,4 %	Chasseurs de promotions

6.4. Métriques d'évaluation

Métrique	Valeur	Interprétation
Silhouette Score	0.2928	Légèrement inférieur à K-means
Calinski-Harabász	884.81	Bon ; légèrement inférieur à K-means
Davies-Bouldin	1.3511	Comparable à K-means
ARI (vs vérité)	0.9498	Légèrement supérieur à K-means

L'ARI de 0.95 de Hclust est remarquable : le clustering hiérarchique retrouve encore mieux les profils réels que K-means. Cela s'explique par le fait que Ward minimise exactement le même critère d'inertie

que K-means, mais en explorant la hiérarchie complète plutôt qu'un minimum local.

6.5. Profils moyens des clusters Hclust

Cluster	Âge	Revenu	Score dépen.	Panier	Fidélité	Ratio promo
0 (Seniors fidèles)	61	35 426 €	50	55,1 €	84	0.20
1 (Familles actives)	37	41 331 €	60	83,8 €	61	0.30
2 (Aisés premium)	43	83 997 €	79	196,0 €	72	0.08
3 (Jeunes économes)	24	18 169 €	36	23,2 €	29	0.48
4 (Chasseurs promo)	36	25 245 €	55	39,3 €	46	0.70


Les profils obtenus sont quasi-identiques à ceux de K-means – témoignant d'une structure de données robuste et de la cohérence des deux méthodes.

7. Visualisations et analyse graphique

7.1. Méthode Elbow (K-means)

La courbe d'inertie en fonction de k montre une décroissance continue avec un coude (*elbow*) observable entre k=3 et k=5. Ce coude indique que l'ajout de clusters au-delà de k=5 n'améliore plus

significativement la compacité des clusters. La méthode Elbow confirme $k=5$ comme choix raisonnable.





7.2. Silhouette Score

Le Silhouette Score maximal est atteint pour $k=3$ (0.319), mais $k=5$ présente un score de 0.293 – perte marginale compensée par une interprétabilité métier bien supérieure. Cette tension entre performance statistique et interprétabilité métier est un enjeu central en Data Science appliquée.

7.3. Projection PCA (K-means et Hclust)

La PCA réduit les 10 dimensions à 2 composantes principales expliquant environ 55-60 % de la variance totale. Les projections 2D révèlent :

- Cinq groupes visuellement distincts malgré la perte d'information
- Le cluster "Aisés Premium" très isolé (revenu et panier bien au-dessus des autres)
- Un chevauchement partiel entre "Jeunes Économes" et "Chasseurs de Promo" (similarités de revenu)




7.4. Dendrogramme hiérarchique

Le dendrogramme tronqué (30 dernières fusions) montre clairement deux niveaux de regroupement naturels :

- Une fusion à haute distance entre le cluster "Aisés Premium" et le reste
- Une structure interne à quatre groupes pour les clients non-premium



La coupure horizontale à la hauteur appropriée isole proprement 5 clusters.



7.5. Heatmaps des profils


Les heatmaps normalisées permettent de comparer visuellement les profils moyens des 5 clusters sur l'ensemble des variables. On observe :

- Le cluster "Aisés Premium" avec revenu et panier très élevés (valeurs max normalisées)
- Le cluster "Seniors Fidèles" avec ancienneté et fidélité maximales
- Le cluster "Chasseurs de Promo" avec ratio promo maximal et fidélité faible




7.6. Boxplots comparatifs

Les boxplots des quatre variables les plus discriminantes (revenu, panier, fidélité, ratio promo) confirment la séparation nette des clusters et la faible dispersion intra-cluster, particulièrement pour K-means.



7.7. Comparaison côte-à-côte

La figure de comparaison PCA côte-à-côte montre que les deux méthodes identifient des partitions quasi-identiques – avec un accord inter-méthodes de ARI = 0.92 – validant la robustesse de la structure détectée.



8. Analyse comparative K-means vs Hclust

8.1. Comparaison quantitative des métriques

Métrique	K-Means	Hclust Ward	Gagnant
Silhouette Score (↑)	0.3002	0.2928	K-Means
Calinski-Harabász (↑)	903.44	884.81	K-Means
Davies-Bouldin (↓)	1.3248	1.3511	K-Means
ARI vs vérité terrain (↑)	0.9204	0.9498	Hclust
Accord inter-méthodes (ARI)	–	0.9213	–

K-Means présente de meilleures métriques internes (cohésion/séparation), tandis que Hclust retrouve légèrement mieux les partitions réelles (ARI externe). Les deux méthodes produisent des partitions fortement concordantes.

8.2. Comparaison qualitative

Dimension	K-Means	Clustering Hiérarchique
Spécification de k	Requis a priori	Peut être choisi a posteriori
Type de résultat	Partition plate	Hiérarchie complète (dendrogramme)
Reproductibilité	Semi-déterministe (init aléatoire)	Déterministe (Ward)

Dimension	K-Means	Clustering Hiérarchique
Scalabilité	Excellente – $O(nkdt)$	Limitée – $O(n^2 \log n)$
Sensibilité outliers	Modérée	Variable selon le linkage
Forme des clusters	Sphérique (convexe)	Variable
Interprétabilité	Centroïdes directs	Dendrogramme (visuel)
Gestion des grandes données	Excellent (mini-batch possible)	Problématique (>50k obs)
Analyse multi-granularité	Non	Oui
Temps de calcul (n=2000)	2.81 s	1.89 s

8.3. Analyse des cas d'usage recommandés

K-Means est préférable quand :

- Le volume de données est grand ($n > 10\ 000$)
- On a une hypothèse a priori sur k
- On souhaite des clusters compacts et sphériques
- La rapidité d'exécution est critique (production, streaming)
- On veut des centroïdes interprétables directement

Hclust est préférable quand :

- On veut explorer la hiérarchie des groupes sans fixer k a priori
- Le volume de données est modéré ($n < 10\ 000$)
- On a besoin d'un outil de visualisation (dendrogramme) pour la présentation
- La structure des données est hiérarchique par nature
- La reproductibilité totale est requise

Dans notre cas : les deux méthodes sont applicables (n=2000). K-Means est légèrement plus compact; Hclust offre le dendrogramme.

Une stratégie hybride – explorer avec Hclust pour choisir k , puis affiner avec K-Means – est souvent optimale.

8.4. Discussion sur la convergence des résultats

Le très fort accord inter-méthodes ($ARI = 0.92$) est une observation importante : il signifie que la structure en 5 clusters n'est pas un artefact d'un algorithme particulier, mais bien une propriété intrinsèque des données. Lorsque K-Means et Hclust s'accordent à ce niveau, le praticien peut avoir une haute confiance dans la validité des clusters identifiés.

Ce phénomène s'explique théoriquement : Ward minimise la même fonction d'inertie que K-Means, mais en parcourant l'espace des partitions de façon déterministe et hiérarchique plutôt que par descente stochastique.

9. Conclusion

Ce travail pratique a démontré la faisabilité et la pertinence du clustering non supervisé pour la segmentation clients dans un contexte de distribution. Les deux algorithmes implémentés – K-Means et Clustering Hiérarchique Agglomératif avec la méthode Ward – ont produit des partitions robustes et cohérentes :

- K-Means ($k=5$) : $ARI=0.92$, Silhouette= 0.30 , convergence en 6 itérations
- Hclust Ward ($k=5$) : $ARI=0.95$, Silhouette= 0.29 , coefficient cophénétique= 0.69
- Accord inter-méthodes : $ARI=0.92$ – très forte convergence confirmant la réalité de la structure

Les 5 segments identifiés (Aisés Premium, Familles Actives, Seniors Fidèles, Jeunes Économes, Chasseurs de Promotions) sont non seulement statistiquement distincts, mais aussi métier-interprétables, ouvrant la voie à des stratégies marketing différenciées et à fort impact.